

Predlog projekta

Predikcija sekundarne strukture proteina
primenom CNN+LSTM arhitekture i evolutivnih metoda optimizacije

Sara Stojkov SV38/2023

1 Naziv teme

Predikcija sekundarne strukture proteina primenom CNN+LSTM arhitekture i evolutivnih metoda optimizacije

2 Definicija problema

Određivanje trodimenzionalne strukture proteina jedan je od centralnih problema molekularne biologije. Sekundarna struktura proteina koja opisuje lokalne geometrijske obrasce polipeptidnog lanca poput α -heliksa, β -ploča i neuređenih (coil) regiona predstavlja ključan međukorak između primarne sekvence aminokiselina i kompletne trodimenzionalne konformacije proteina. Tačna predikcija sekundarne strukture direktno utiče na razumevanje funkcije proteina, projektovanje novih lekova i razvoj terapija za bolesti uzrokovane pogrešnim savijanjem proteina (eng. *protein misfolding*), kao što su Alchajmerova i Parkinsonova bolest.

Eksperimentalne metode određivanja strukture proteina, poput rendgenske kristalografije i NMR spektroskopije, izuzetno su skupe i vremenski zahtevne. Zbog toga računarski pristup predikciji sekundarne strukture ima značajan praktičan i ekonomski potencijal, ubrzavanje procesa otkrivanja lekova, smanjenje troškova istraživanja i omogućavanje analize proteina za koje eksperimentalno određivanje strukture nije izvodljivo.

Centralni doprinos ovog projekta nije samo primena *deep learning* metoda na navedeni problem, već sistematsko istraživanje i poređenje različitih metaheurističkih metoda optimizacije: evolutivnih algoritama, optimizacije rojem čestica i Bayesove optimizacije u kontekstu pronalaženja optimalnih hiperparametara modela, uz analizu njihove efikasnosti, brzine konvergencije i kvaliteta pronađenih rešenja.

3 Skup podataka

Za treniranje i evaluaciju modela koriste se dva standardna skupa podataka koja se uveliko primenjuju u literaturi za predikciju sekundarne strukture proteina.

CullPDB5926 sadrži 5926 proteina izdvojenih iz Protein Data Bank (PDB) baze podataka korišćenjem PISCES culling servera, pri čemu je obezbeđeno da sekvencna sličnost

između proteina ne prelazi 25%, čime se smanjuje redundantnost podataka. Svaki protein je predstavljen sekvencom aminokiselina enkodiranih kao *one-hot* vektori dimenzionalnosti 21 (20 standardnih aminokiselina i jedna klasa za nepoznate ostatke), zajedno sa profilima evolucione konzerviranosti (PSSM – Position-Specific Scoring Matrix) dimenzionalnosti 21 po ostatku. Ukupna dimenzionalnost ulaznog vektora po aminokiselinskom ostatku iznosi 42. Skup podataka je podeljen na trening skup (5534 proteina) i validacioni skup (256 proteina).

CB513 je nezavisni test skup od 513 proteina koji se koristi isključivo za finalnu evaluaciju modela, a nikako tokom treniranja ili podešavanja hiperparametara. Ovaj skup omogućava direktno poređenje dobijenih rezultata sa rezultatima iz objavljenih radova.

Ciljno obeležje je diskretna oznaka sekundarne strukture na nivou svakog aminokiselinskog ostatka, i uzima jednu od tri vrednosti: **H** (α -heliks), **E** (β -ploča) i **C** (coil, tj. neuređeni region). Problem se dakle formuliše kao sekvenčna višeklasna klasifikacija (sequence-to-sequence, 3-class).

Skupovi podataka dostupni su na sledećim lokacijama:

- CullPDB5926 i CB513 u NumPy formatu (trening + test): https://github.com/taneishi/CB513_dataset
- CB513 na Kaggle: <https://www.kaggle.com/datasets/moklesur/cb513-dataset-for-protein>

4 Metodologija

Rešenje se sastoji iz dva međusobno povezana dela: (1) dizajna i treniranja CNN+LSTM modela za predikciju sekundarne strukture, i (2) primene i poređenja metaheurističkih optimizacionih algoritama za pronalaženje optimalnih hiperparametara tog modela.

Arhitektura modela

Predložena arhitektura kombinuje konvolutivne i rekurentne slojeve:

- **Ulazni sloj:** sekvenca vektora dimenzionalnosti 42 po ostatku (*one-hot encoding* + PSSM profil)
- **Konvolutivni blok:** jedan ili više 1D konvolutivnih slojeva sa ReLU aktivacijom i batch normalizacijom, koji lokalno agreguju kontekst susednih aminokiselina (prozor veličine 3–7 ostataka). Konvolucija omogućava efikasno izdvajanje lokalnih motiva u sekvenci.
- **Rekurentni blok:** dvosmeran LSTM sloj (BiLSTM) koji modeluje dugoročne zavisnosti u sekvenci u oba smera, čime se uzima u obzir i levi i desni kontekst svakog ostatka.
- **Izlazni sloj:** potpuno povezan sloj sa softmax aktivacijom koji za svaki ostatak daje raspodelu verovatnoća nad tri klase (H, E, C).
- **Regularizacija:** dropout između slojeva.

Optimizacioni deo

Hiperparametarski prostor koji se pretražuje uključuje: broj konvolutivnih filtera, veličinu konvolutivnog prozora, broj LSTM jedinica, stopu učenja, koeficijent dropout-a i veličinu batch-a. Biće implementirani i međusobno poređeni sledeći pristupi:

1. **Genetski algoritam (GA):** populacija hiperparametarskih konfiguracija evoluira kroz selekciju, ukrštanje i mutaciju. Fitnes funkcija je validaciona Q3 tačnost modela treniranog sa datom konfiguracijom.
2. **Optimizacija rojem čestica (PSO):** čestice pretražuju hiperparametarski prostor vođene sopstvenim najboljim pozicijama i globalnim optimumom roja.
3. **Bayesova optimizacija:** koristi Gaussian Process surogatni model fitnes funkcije kako bi efikasno birala naredne tačke za evaluaciju, balansirajući istraživanje i eksploataciju prostora.
4. **Bazni pristup:** nasumična pretraga hiperparametara (Random Search) kao referentna linija za poređenje.

Svi optimizacioni algoritmi (GA, PSO) biće implementirani od nule u Python-u, bez korišćenja gotovih biblioteka za metaheuristike, kako bi se steklo dublje razumevanje njihovog funkcionisanja.

5 Način evaluacije

Evaluacija modela

Standardna metrika za ovaj problem je **Q3 tačnost** (eng. *Q3 accuracy*) – procenat ostataka za koje je sekundarna struktura tačno predviđena u sve tri klase:

$$Q3 = \frac{\text{broj tačno klasifikovanih ostataka}}{\text{ukupan broj ostataka}} \times 100\%$$

Pored Q3 tačnosti, računaće se i **F1 skor** po klasi kako bi se detektovala eventualna neravnoteža u performansama između klasa H, E i C, i **konfuziona matrica** na CB513 test skupu.

Evaluacija optimizacionih algoritama

Optimizacioni algoritmi poređeni su prema:

- Finalnom kvalitetu pronađenog rešenja (Q3 tačnost najboljeg modela)
- Brzini konvergencije (Q3 tačnost u funkciji broja evaluacija modela)
- Ukupnom računarskom trošku (vreme pretrage)

Rezultati će biti vizualizovani kroz krive konvergencije za svaki algoritam.

6 Tehnologije

- **Python 3.10+** primarni programski jezik

- **PyTorch** implementacija CNN+LSTM arhitekture, treniranje modela, računanje gradijenata
- **NumPy** manipulacija nizovima, implementacija GA i PSO algoritama od nule
- **scikit-learn** računanje metrika evaluacije (F1, konfuziona matrica), Bayesova optimizacija (BayesSearchCV)
- **Matplotlib** / **Seaborn** vizualizacija krivih konvergencije i rezultata evaluacije
- **Google Colab** / **lokalni GPU** okruženje za treniranje modela

7 Primeri gotovih rešenja

- Pregled metoda predikcije sekundarne strukture i poređenje rezultata (JPRED, PSIPRED, NetSurf-2): <https://www.compbio.dundee.ac.uk/jpred/>
- PSIPRED – jedan od najkorišćenijih alata za predikciju sekundarne strukture: <http://bioinf.cs.ucl.ac.uk/psipred/>

8 Relevantna literatura

1. Zhou, J., & Troyanskaya, O. G. (2014). *Deep supervised and convolutional generative stochastic network for protein secondary structure prediction*. ICML 2014. <https://arxiv.org/abs/1403.1347>
2. Li, Z., & Yu, Y. (2016). *Protein Secondary Structure Prediction Using Cascaded Convolutional and Recurrent Neural Networks*. IJCAI 2016. <https://arxiv.org/abs/1604.07176>
3. Kennedy, J., & Eberhart, R. (1995). *Particle swarm optimization*. Proceedings of ICNN'95.
4. Holland, J. H. (1992). *Adaptation in Natural and Artificial Systems*. MIT Press.
5. Snoek, J., Larochelle, H., & Adams, R. P. (2012). *Practical Bayesian Optimization of Machine Learning Algorithms*. NeurIPS 2012. <https://arxiv.org/abs/1206.2944>
6. RCSB Protein Data Bank: <https://www.rcsb.org/>